



Вештачка интелигенција

Проектна задача

Детекција на коловозни ленти и објекти во
сообраќајот

Илија Бунчески – 221094



Вовед

Вештачката интелигенција и машинската визија играат клучна улога во напредокот на различни индустрии, а една од најзначајните примени е во интелигентните транспортни системи. Машинската визија овозможува машините да анализираат и интерпретираат визуелни податоци, што овозможува развој на автоматизирани и паметни решенија за управување со сообраќајот.

Еден од најзначајните предизвици во оваа област е детекцијата на објекти и коловозни ленти во сообраќајот. Оваа технологија користи алгоритми за машинско учење за препознавање на возила, пешаци, сообраќајни знаци и обележани ленти на патот. Способноста на системите автоматски да го анализираат сообраќајот носи големи придобивки во неколку клучни области:

Подобрена безбедност во сообраќајот

Детекцијата на објекти и ленти овозможува имплементација на напредни системи за помош на возачите (ADAS - Advanced Driver Assistance Systems). Овие системи вклучуваат автоматско одржување во лента, предупредување за судири, автоматско сопирање и други работи кој се од голема помош на возачите. Со тоа се намалува ризикот од несреќи предизвикани од човечки грешки, кои се најчест причинител на сообраќајни инциденти.

Автономни возила

Автономните возила се потпираат на софистицирани алгоритми за машинско учење за да детектираат и предвидуваат движења на сообраќајните учесници. Детекцијата на ленти им помага да останат во рамките на сообраќајните обележја, додека идентификацијата на објекти овозможува избегнување на пешаци, други возила и препреки. Овие возила комбинираат податоци од повеќе сензори (камери, LiDAR, радар) за да создадат прецизен модел на околината и да носат одлуки во реално време.

Управување со сообраќајот

Интелигентните транспортни системи користат детекција на објекти за да го следат сообраќајниот тек и да носат оптимални одлуки за управување со сообраќајот. Ова овозможува поефикасно регулирање на семафорите, намалување на метежот и подобрување на протокот на возила. Ваквите системи можат да идентификуваат и анализираат сообраќајни прекршоци, како што се недозволен престигнувања или поминување на црвено светло.



Преглед на сродни истражувања

Техники за процесирање на слика

- **Филтрирање и заматување (Filtering and Blurring):**
 - Гаусово заматување (Gaussian Blur): Се користи за намалување на шумот и измазнување на сликата.
- **Сегментација на слика (Image Segmentation):**
 - Thresholding: Поделба на сликата на региони врз основа на нивото на интензитет.
 - K-means Clustering: Групирање на пиксели според нивната боја или интензитет.
- **Морфолошки операции (Morphological Operations):**
 - Ерозија и дилатација (Erosion and Dilation): Користени за подобрување на структурите во бинарните слики.

Техники за детекција на објекти во сообраќај

- **Методи базирани на традиционални компјутерски алгоритми:**
 - Background Subtraction: Користен за детекција на движечки објекти во видео секвенци.
 - Optical Flow: Користен за следење на движење на објекти во временски рамки.
- **Методи базирани на невронски мрежи:**
 - Mask R-CNN: Комбинација на детекција на објекти и сегментација на инстанци.
 - EfficientDet: Ефикасен модел за детекција на објекти со баланс помеѓу точност и брзина.
 - RetinaNet: Користи Focal Loss за подобрување на перформансите при детекција на мали објекти.



Техники за детекција на сообраќајни ленти

- **Класични методи:**
 - Color Thresholding: Користен за идентификација на ленти врз основа на бојата.
- **Методи базирани на невронски мрежи:**
 - SCNN (Spatial CNN): Специјализирана архитектура за детекција на ленти, особено корисна за криви ленти.
 - ENet: Ефикасна мрежа за realtime сегментација на ленти.

Техники за подобрување на перформансите

- Transfer Learning: Користење на претходно обучени модели за подобрување на точноста и намалување на времето за тренирање.
- Ensemble Methods: Комбинирање на предвидувањата од повеќе модели за подобрување на точноста.

Техники за анализа на сообраќајни ситуации

- Trajectory Prediction: Предвидување на движењето на возилата и пешаците.
- Behavior Analysis: Анализа на однесувањето на учесниците во сообраќајот за идентификација на потенцијални опасности.
- Traffic Density Estimation: Проценка на густината на сообраќајот врз основа на бројот на детектирани објекти.



Опис на користена методологија

Во овој дел ќе биде објаснет изборот на модел, а потоа ќе биде објаснето како е постигнато врз секој frame од видеото да бидат обележани линиите и присутните објекти.

Избор на постоечки модел

Најпрво се обидов да ги искористам готовите модели [EfficientDet](#)(EfficientDet D4) и [Faster R-CNN](#) кој беа pre-trained на COCO dataset-от. Иако овие модели даваа прилично добри резултати, нивното претходно тренирање на податочно множество што содржеше многу повеќе класи од потребното(кола, камион, пешак...) допринесе тие да даваат чудни детекции на објекти кои не беа присутни на сликите. Притоа, поради ограничувањата на хардверот на мојот систем, кај овие два модели воочливо беше дека треба доста време за да се добијат нивните резултати.

Следно, се одлучив да го искористам [YOLOv8](#) моделот. Прво нешто што приметив е дека иако резултатите беа прилично слични, времето кое што беше потребно да се изврши детекцијата беше пократко во споредба со претходните два модели. Но, и тука го имав истиот проблем кој што го имав и со претходните два модели, односно сèуште беа детектирани објекти кои не постоеа на сликите и воопшто не би можеле да бидат дел од сообраќајот.

Донесов одлука дека ќе го користам YOLOv8 моделот за детекција на објекти и дополнително ќе го fine-тунирам на друго податочно множество кое што се содржи само од објекти кои се пристуни во сообраќајот. Главната одлука за избор на овој модел беше неговата ефикасност, односно резултатите од овој модел беа многу слични со резултатите на претходните модели, а се добиваа за пократко време.

YOLOv8 е една од поновите верзии на YOLO(You Only Look Once) фамилијата на модели. Неговата архитектура се состои од 3 главни компоненти:

1. Backbone: Конволуциска невронска мрежа (CNN) која ги извлекува карактеристиките од сликата. YOLOv8 користи прилагоден CSPDarknet53 backbone, кој со користење на cross-stage partial врски го подобрува преносот на информации и ја зголемува прецизноста.
2. Neck: Го спојува output-от(feature maps) од Backbone-от за да долови битни информации од дадениот input.
3. Head: Оваа компонента ги прави предвидувањата врз основ на информациите добиени од невроните во претходните две компоненти. Тука се прават предвидувања за границите на објектите(bounding boxes) и класната веројатност.

Избор на податочно множество

По истражувањето кое го направив околу податочните множества, ги најдов следните: [Venom Dataset](#), [Udacity Self Driving Dataset](#), [NO2 Dataset](#). По тренирање на моделот со секое од наведените податочни множества, најдобри резултати врз тест видеото даваше моделот кој беше истрениран на NO2 Dataset-от, па така за мојот проект се одлучив дека ќе го користам YOLOv8 моделот истрениран на NO2 Dataset-от.

Податоци

Бидејќи податоците не беа поделени на тренирачко и валидациско множество тоа го направив во сооднос 80% од податоците за тестирање и 20% од податоците за валидација, односно 7952 слики беа користени за тренирање на моделот и 1988 за валидација.

Секој од податоците кои се користат како влез за моделот се состои од два „дела“ – сликата во .jpg формат и местоположбата на објектите во сликата сместени во тесктуална датотека во .txt формат.

Податоците кој се даваат како влез на моделот при процесот на тренирање се сместени во фолдер кој се состои од два други фолдери – images и labels. Секој од податоците од едниот фолдер мора да има соодветен „пар“ во другиот фолдер со исто име и соодветната екстензија.

Пример за како изгледа обележувањето на објект во дадена слика:

Формат: **class index x_center y_center width height**

2 0.29833984375 0.5269565217391304 0.0263671875 0.03739130434782609 каде што

- **2** е индексот на класата.
- **0.29833984375** е x-координатата на центарот на ограничувачката кутија (bounding box), нормализирана во однос на ширината на сликата (опсег од 0 до 1).
- **0.5269565217391304** е y-координатата на центарот на ограничувачката кутија, нормализирана во однос на висината на сликата (опсег од 0 до 1).
- **0.0263671875** е ширината на ограничувачката кутија, нормализирана во однос на ширината на сликата (опсег од 0 до 1).
- **0.03739130434782609** е висината на ограничувачката кутија, нормализирана во однос на висината на сликата (опсег од 0 до 1).

Овој формат е често користен во задачи за детекција на објекти, како на пример во моделите YOLO (You Only Look Once).



Тренирање

Модел за детекција на објекти


Откако податоците беа спремни, тренирањето на моделот беше извршено со следните параметри:

```
model.train(  
    data=data_yaml_path,  
    epochs=20,  
    imgsz=800,  
    batch=16,  
)
```

Optimizer-от и ратата на учење на моделот беа оставени на предефинираното подесување. Големината на batch-от беше поставена на 16 бидејќи се соочив со хардверско ограничување, додека одлуката за бројот на епохи беше донесена по извршување на процесот на тренирање неколку пати. Сметам дека 20 е прилично оптимално бидејќи во последните епохи не забележував значително намалување на загубата, а воедно процесот на тренирање беше доста долг.


Детекција на коловозни ленти

Pretrained моделот ENet даваше солидни резултати па се одлучив да го користам без дополнително тренирање.



Слика 1. Изглед на еден batch при тренирање на моделот за детекција на објекти

Резултати од тренирање и валидација врз валидациско множество



Losses

- **train/box_loss, train/cls_loss, train/dfl_loss** – Загубите опаѓаат стабилно, што укажува на добро учење на моделот.
- **val/box_loss, val/cls_loss, val/dfl_loss** – Валидациските загуби исто така покажуваат опаѓање, што значи дека моделот не overfit-ува и генерално се подобрува.

Precision & Recall

- **precision, recall** – Прецизноста осцилира, но генерално се зголемува, што значи дека моделот сè подобро ги предвидува објектите додека recall-от има стабилно зголемување, што значи дека моделот открива повеќе објекти во сликите.

mAP (Mean Average Precision)

- **metrics/mAP50 и metrics/mAP50-95** – mAP се зголемува низ епохите, што покажува дека моделот станува подобар во детекцијата низ различни големини на објекти и IoU прагови.
- **IoU (Преклопување врз унија)** е метрика што покажува колку добро се преклопуваат предвидената рамка (bounding box) и вистинската рамка (ground truth).
- **mAP50** – Ја мери просечната прецизност (AP) при еден фиксен праг на **IoU = 0.50**. Тоа значи дека предвидената рамка (bounding box) ќе се смета за



точна ако нејзиното преклопување со вистинската рамка е барем 50%. Ова е **попустлив критериум** и генерално дава повисоки вредности.

- **mAP50-95 (mAP50-95)** – Ова е **просечната вредност на AP пресметана на повеќе IoU прагови** (0.50, 0.55, 0.60, ..., 0.95). Оваа метрика е **построга** бидејќи бара моделот да има добри детекции дури и при високи IoU вредности.

Краток опис на кодот за обработка на видео

Кодот е поделен на неколку клучни функции, кои работат во синхронизација за да го постигнат саканиот резултат.

1. Вчитување на моделите

- Функција: `load_lane_model`
 - Се вчитува моделот за детекција на ленти (ENet)
- Функција: `load_yolo_model`
 - Се вчитува YOLO модел за детекција на објекти користејќи ја библиотеката `ultralytics`.

2. Препроцесирање на сликите

- Функција: `preprocess_frame_for_lane_detection`
 - Сликата се претвора во `grayscale` за да се намали комплексноста на податоците, се менува во големина и се трансформира во `tensor` со соодветна димензионалност за да може да се обработи од страна на моделите

3. Детекција на сообраќајни ленти

- Функции: `detect_lanes` и `postprocess_lane_detection`
 - Се врши детекција на лентите користејќи го ENet моделот.



4. Преклопување на детектираните ленти

- Функција: `overlay_lane_mask`
 - Оваа функција овозможува визуелизација на детектираните ленти врз оригиналната слика.
-

5. Детекција на објекти

- Функција: `detect_objects`
 - Се користи YOLO моделот за детекција на објекти во сликата.
 - Резултатите се визуелизирани на сликата со правоаголници и ознаки.
-

6. Комбинирање на резултатите

- Функција: `process_video_frame`
 - Се комбинираат резултатите од детекцијата на ленти и објекти.
 - Двете визуелизации се преклопуваат на оригиналната слика
-

7. Обработка и зачувување на видеоснимката


- Функција: `process_and_save_video`
 - Се вчитува влезното видео и се подготвува излезното видео за зачувување.
 - Видеото се зачувува на наведената патека.
-

8. main

- Се вчитуваат моделите за детекција на ленти и објекти.
- Се повикува функцијата `process_and_save_video` за да се изврши обработката на видеото.



Приказ на способноста на моделот преку слики и видеа





Линк до видеата каде што може да се види како функционира моделот за детекција на коловозни ленти заедно со моделот за детекција на објекти:

Видео 1: [video1](#)

Видео 2: [video2](#)

Заклучок

Развојот на технологиите за машинска визија и вештачката интелигенција има значително влијание врз подобрувањето на сообраќајната безбедност и ефикасност. Овој проект се фокусираше на имплементација на модел за детекција на објекти и коловозни ленти, користејќи современи алгоритми базирани на длабоко учење. Преку комбинација на модели како **ENet** за детекција на коловозни ленти и **YOLO** за детекција на објекти, успешно беше достигната целта.

Идни насоки за подобрување:

- **Подобрување на точноста:** Со употреба на поголеми и поразновидни тренинг множества, како и со тестирање на повеќе вредности за хиперпараметрите, можно е да се подобри точноста на моделите.
- **Проширување на функционалноста:** Идните верзии на проектот може да вклучат дополнителни функционалности, како на пример, предвидување на движењето на објекти.

Овој проект го демонстрира потенцијалот на машинската визија и вештачката интелигенција во областа на сообраќајната анализа. Иако постигнатите резултати се прилично добри, постои простор за дополнително истражување и подобрување. Со постојаното усовршување на алгоритмите и технологиите, овие решенија можат да придонесат за создавање на посигурни, поефикасни и поинтелигентни транспортни системи во иднина.